

Data Understanding Report

1. Informasi Umum Dataset

Nama Dataset	Cyber Breach Analysis Dataset
Nama File	breached_services_info.csv
Sumber	Have I Been Pwned (HIBP) — data kebocoran yang dikurasi oleh Troy Hunt; disediakan sebagai dataset publik di Kaggle (oleh GojoYuno) dan dipakai sebagai sumber dashboard "Cyber Breach Analysis".
Bentuk	Structured Data (tabel CSV) — 17 kolom + 1 kolom index
Jumlah Data	777 baris (insiden kebocoran data)
Jumlah Variabel	17 variabel (fitur) + 1 variabel index
Rentang Waktu	2007 – 2024 (berdasarkan BreachDate)

2. Deskripsi Dataset

Dataset ini berisi katalog kebocoran data (data breach) dari berbagai layanan online di seluruh dunia, yang dikumpulkan dan diverifikasi oleh layanan Have I Been Pwned. Setiap baris mewakili satu insiden kebocoran pada satu layanan, dan mencatat nama layanan, domain, tanggal kebocoran, jumlah akun yang terdampak (PwnCount), jenis data yang bocor (DataClasses), serta sejumlah flag atribut (terverifikasi, sensitif, spam, malware, dan lain-lain).

3. Tujuan Dataset

Menyediakan data historis kebocoran data untuk dianalisis oleh peneliti, analis keamanan siber, dan data analyst guna memahami frekuensi, skala, dan pola kebocoran data dari waktu ke waktu — termasuk jenis data yang paling sering bocor, layanan/domain yang paling sering menjadi sasaran, serta tingkat keseriusan tiap insiden.

4. Target Analisis & Variabel Penting

Target Variable	PwnCount (jumlah akun/rekor yang terdampak) — mengukur skala/severity tiap kebocoran.
Feature utama	BreachDate (waktu), Domain, DataClasses (jenis data bocor), IsVerified, IsSensitive, IsSpamList, IsMalware.
Kunci identitas	Name (nama layanan) — 777 nilai unik, bertindak sebagai primary key.

5. Potensi Insight

- Email addresses adalah jenis data yang paling sering bocor (muncul di 771 insiden), diikuti Passwords (587), Usernames (406), dan Names (379).
- Total akun yang terekspos mencapai lebih dari 13,5 miliar, dengan puncak aktivitas kebocoran pada tahun 2016.
- Breach terbesar dalam dataset adalah Collection #1 dengan 772.904.991 akun.
- Sebagian besar insiden (737) terverifikasi, sedangkan 61 insiden ditandai sebagai data sensitif.

- Pola pengulangan lebih banyak terjadi pada level domain dibanding nama layanan, mengindikasikan target/komunitas yang berulang.

6. Kelebihan Dataset

- Data terstruktur dan sudah terstandarisasi (HIBP), mudah dibaca dengan Pandas/Excel.
- Mencakup rentang waktu panjang (2007–2024) dan skala global, kaya untuk analisis tren.
- Memiliki variabel kuantitatif (PwnCount) dan banyak atribut flag yang berguna untuk analisis & klasifikasi.
- DataClasses memberikan rincian jenis data yang bocor — kaya untuk analisis kategori.
- Sudah terdokumentasi dengan file deskripsi kolom (about_the_dataset.txt).

7. Kekurangan / Keterbatasan Dataset

- Kolom tanggal masih berupa teks (perlu konversi ke datetime); DataClasses berbentuk string mirip list Python (perlu parsing).
- Terdapat 38 baris dengan nilai kosong pada kolom Domain.
- Kolom Description mengandung tag HTML, perlu dibersihkan untuk analisis teks murni.
- Kebocoran yang tidak dilaporkan/terdeteksi tidak masuk dataset (cakupan bergantung pada pelaporan HIBP), sehingga berpotensi bias terhadap insiden yang terpublikasi.
- PwnCount adalah jumlah akun yang terekspos, bukan jumlah korban unik, dan bisa mencakup duplikasi antar-kebocoran.