

Dataset Summary

Simulasi Industri Junior Data Analyst — Minggu 2: Data Collection & Understanding (Day 4 / Kamis)

1. Screenshot Dataset (8 baris pertama)

Name	Title	Domain	BreachDate	PwnCount	IsVerified
000webhost	000webhost	000webhost.com	2015-03-01	14936670	True
123RF	123RF	123rf.com	2020-03-22	8661578	True
126	126	126.com	2012-01-01	6414191	False
17Media	17	17app.co	2016-04-19	4009640	True
17173	17173	17173.com	2011-12-28	7485802	False
2844Breaches	2,844 Separate Data Breaches	2844breaches.com	2018-02-19	80115532	False
2fast4u	2fast4u	2fast4u.be	2017-12-20	17706	True
500px	500px	500px.com	2018-07-05	14867999	True

Cuplikan 8 baris pertama dataset (sebagian kolom).

2. Statistik Dasar

Metrik	Nilai
Jumlah baris (records)	777 insiden kebocoran
Jumlah kolom	17 variabel (+ 1 index)
Total akun terekspos	13.517.282.665
Breach terbesar (max PwnCount)	772.904.991 (Collection #1)
Rata-rata (mean) PwnCount	17.396.756
Median PwnCount	1.141.278
Std dev PwnCount	70.068.858
PwnCount min / max	858 / 772.904.991
Rentang tahun kebocoran	2007 – 2024
Tahun puncak kebocoran	2016

3. Missing Value



Total nilai kosong: **38**, seluruhnya pada kolom **Domain** (5% dari 777 baris). Kolom lain tidak memiliki nilai kosong.

4. Jumlah Nilai Unik per Kolom

Kolom	Jumlah Unik
Name	777 (unik → primary key)
Title	777
Domain	720
BreachDate	650
AddedDate	773
ModifiedDate	768
PwnCount	776
Description	777
DataClasses	401
IsVerified / IsFabricated / IsSensitive / IsRetired / IsSpamList / IsMalware / IsSubscriptionFree	2 (True/False)

5. Insight Awal

- Email addresses adalah jenis data paling sering bocor (771 insiden), diikuti Passwords (587) dan Usernames (406).
- Total lebih dari 13,5 miliar akun terekspos dengan puncak kebocoran pada tahun 2016.
- Breach terbesar adalah Collection #1 (772,9 juta akun); sebaran PwnCount sangat miring (mean jauh di atas median).
- Sebagian besar insiden (737) terverifikasi; 61 insiden ditandai sensitif.
- Pola pengulangan lebih menonjol pada level domain (mis. ogusers.com 4x) dibanding nama layanan.



Kiri: Jumlah kebocoran per tahun. Kanan: Jenis data paling sering bocor (Top 8).